Herramientas de código abierto para conectar las colecciones mastozoológicas y sus datos con la macroecología

Luis D. Verde Arregoitia

Laboratorio de Macroecología Evolutiva, Red de Biología Evolutiva, Instituto de Ecología A. C. (INECOL)

2026-10-15

Macroecología

- Patrones geográficos de diversidad y rasgos de especies, en un contexto ecológico y evolutivo
- Escalas temporales y espaciales amplias

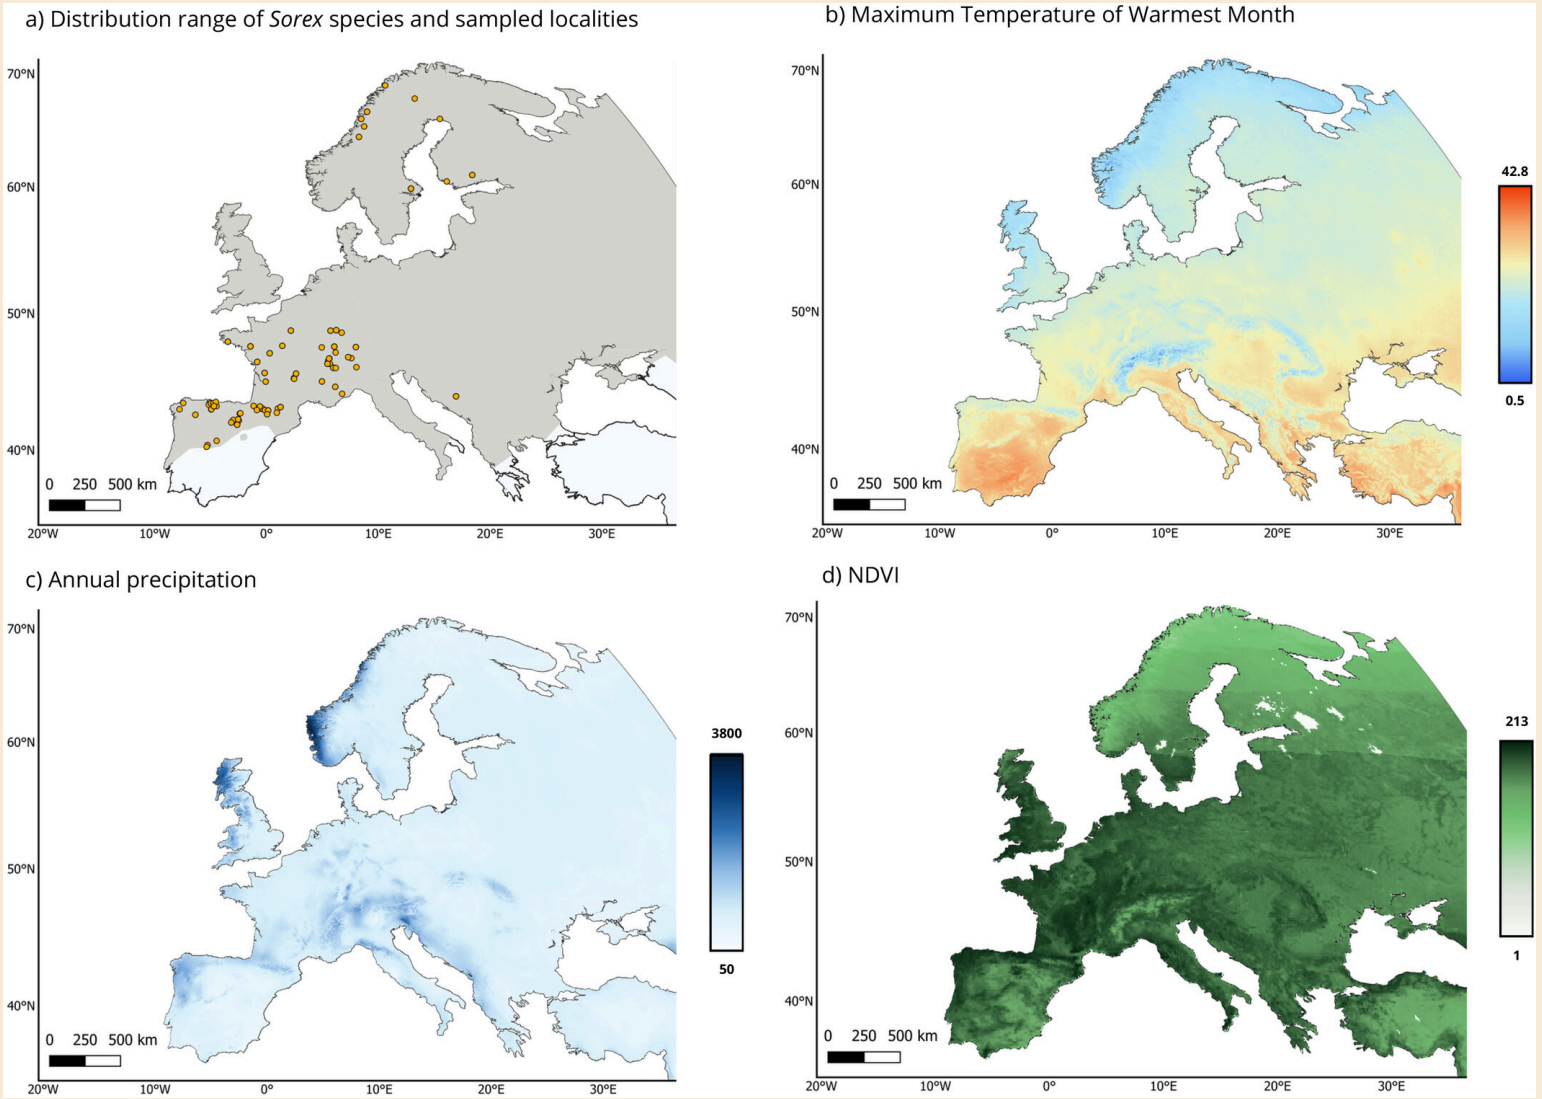

Valle-Cabo et al. 2026. J. Biog.

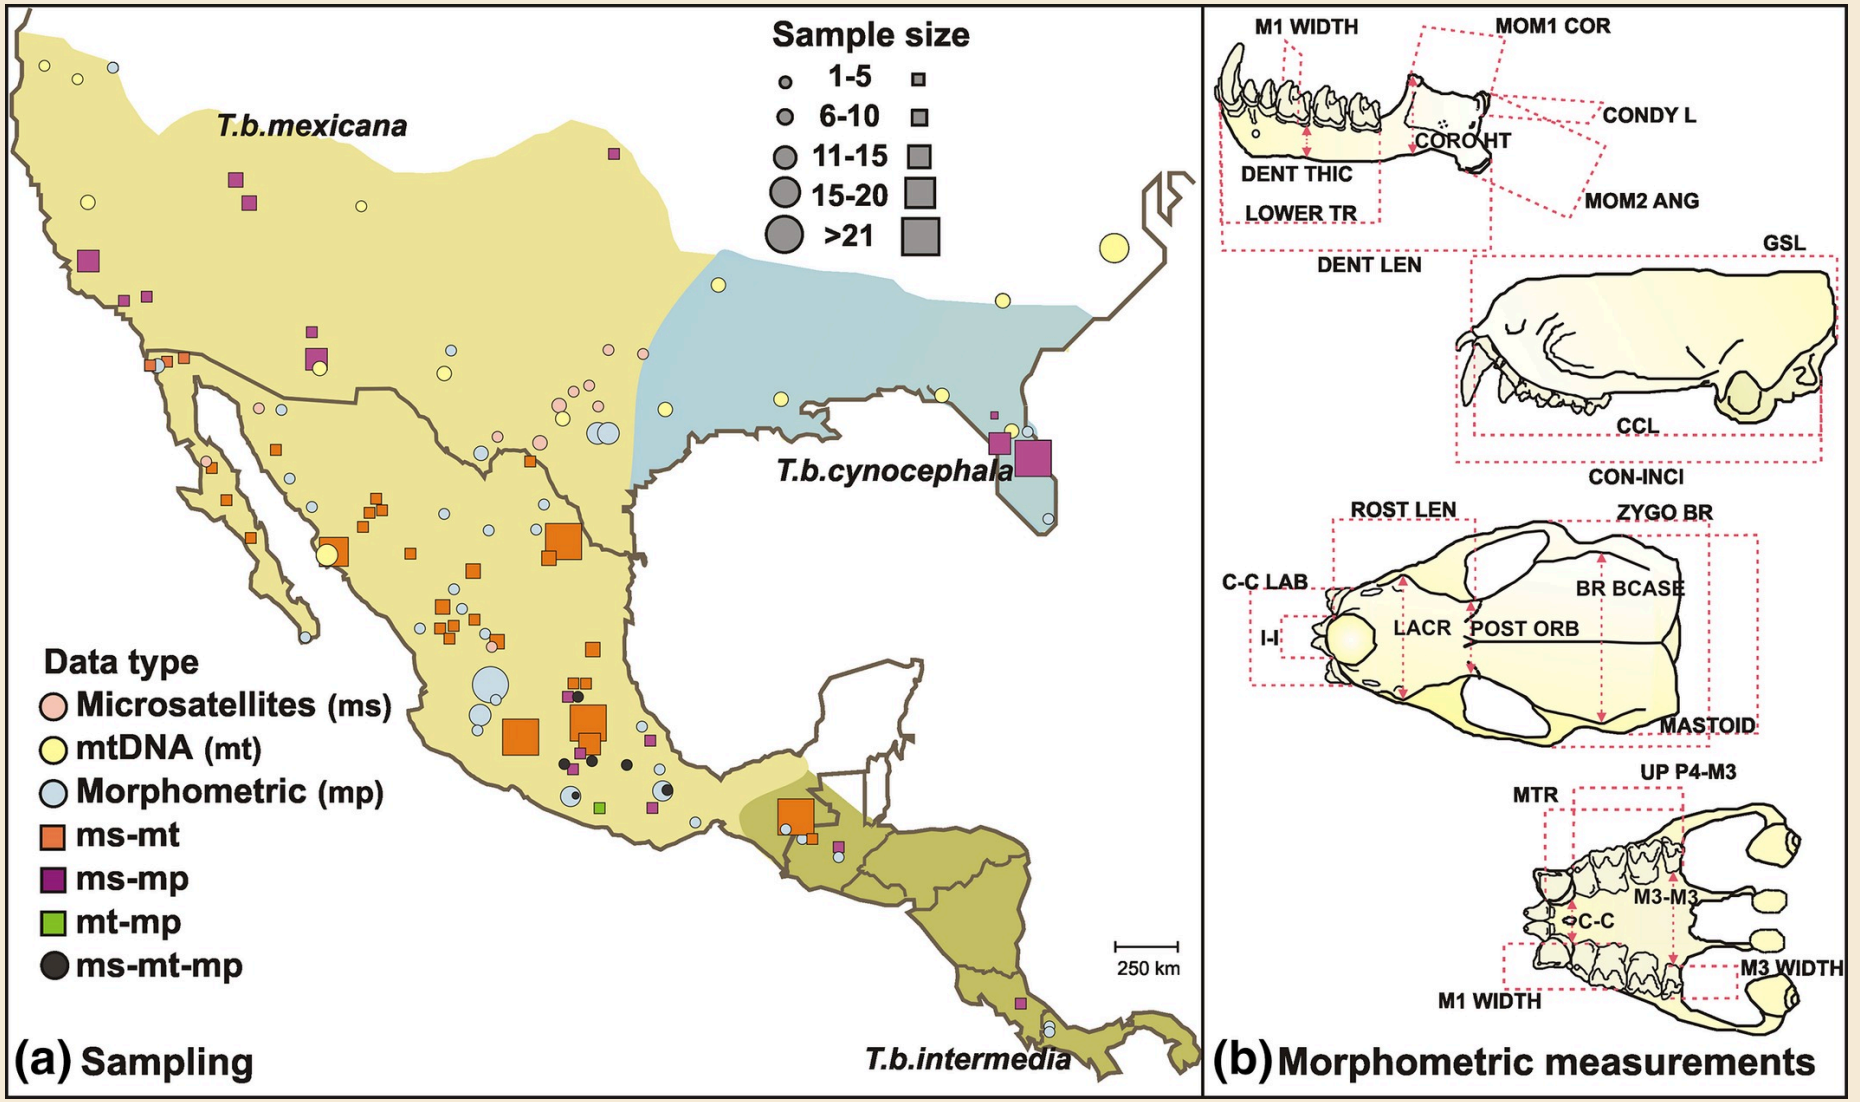

Morales et al. 2016. J. Biog.

Colecciones

- Fuente de datos morfólogicos, genéticos y de distribución
- Valor incalculable para todo tipo de estudios

Desafíos

- Alta proporción de datos sobre distribución y fenotipos que permanece **inaccesible** digitalmente
- **Cuello de botella técnico** entre los materiales en colecciones, sus datos derivados, y su integración en análisis macroecológicos

Oportunidades

- Métodos de alto rendimiento para almacenar y procesar **millones de registros** en equipos modestos
- Modelos de visión artificial para extraer datos desde archivos PDF, etiquetas, diarios de campo, etc.

Herramientas de código abierto

¿Por qué importa?

- Requerimientos informáticos **menores** (equipo de cómputo existente)
- Entornos de programación gratuitos: R o Python y formatos abiertos
- Análisis reproducible y escalable

Datos para ejemplos

- **GBIF**: ~4 millones de registros de roedores (2 GB CSV)
- **Datos espaciales**: GeoPackage con geometrías de aves (BOTW)
- **PDFs**: documentos escaneados con fichas de especies

Roedores en GBIF

- 3.96 millones de filas, 50 columnas
- Todos con coordenadas

De CSV a Parquet

Apache Arrow en memoria, Parquet en disco

Formato columnar muy eficiente

```r
library(arrow)

csv_ds <- open_dataset(
  "data/0129482-230530130749713.csv",
  format = "text",
  schema = schema(.default = string()),  # todo como texto
  parse_options = csv_parse_options(delimiter = "\t", quoting = FALSE)
)
write_dataset(csv_ds, "data/gbif_mammals.parquet", format = "parquet")
```

7× menos espacio

Archivo	Tamaño
Descarga zip	309 MB
CSV (DarwinCore)	2.1 GB
Parquet (mismos datos)	**283 MB**

Conversión: **104 segundos**, una sola vez

Leer 3.96 millones de registros

Laptop Lenovo X1 de uso diario (16 GB RAM):

Método	Tiempo
`read.delim()` (R base - CSV)	~8 min
`read_parquet()` (arrow)	**19.5 s**

~25× más rápido que R base

Consultar sin cargar todo en memoria

```r
# La consulta filtrada solo trae a R lo necesario:
mx <- open_dataset("data/gbif_mammals.parquet") |>
  dplyr::filter(countryCode == "MX") |>
  dplyr::collect()
```

Consulta	Tiempo
Filtrar `countryCode == “MX”	**11.7 s**

Procesamos todos los registros, llegan a memoria 203,602 de México

Más consultas

Operaciones de conteo, promedios, agrupaciones y mucho más en **~2 segundos** cada una:

¿Qué familia tiene más registros?

```
1 ds <- open_dataset("data/gbif_mammals.parquet")
2
3 ds |> dplyr::count(family, sort = TRUE) |> dplyr::collect()
```

family	n
Cricetidae	1,958,691
Muridae	735,179
Sciuridae	675,693
Castoridae	226,201
Heteromyidae	130,936

¿Qué países están más representados?

```
1  ds |> dplyr::count(countryCode, sort = TRUE) |> dplyr::collect()
```

countryCode	n
NL	1,012,924
US	484,672
FR	359,835
GB	341,413
AU	327,526

¿Por qué tantos registros en Países Bajos?

Registros por institución y tipo

```
ds |>
  dplyr::filter(countryCode == "NL") |>
  dplyr::count(institutionCode, basisOfRecord, sort = TRUE) |>
  dplyr::collect()
```

institutionCode	basisOfRecord	n
Unie Van Waterschappen	HUMAN_OBSERVATION	519,711
	HUMAN_OBSERVATION	490,123
MammalSocNL	HUMAN_OBSERVATION	1,624
NMR	PRESERVED_SPECIMEN	394

Control de fauna por autoridades de agua

```
ds |>
  dplyr::filter(countryCode == "NL",
                institutionCode == "Unie Van Waterschappen") |>
  dplyr::count(species, sort = TRUE) |>   dplyr::collect()
```

species	n
Ondatra zibethicus (rata almizclera)	511,356
Myocastor coypus (coipo)	8,355

519,711 registros de especies invasoras, más que todos los ejemplares de todas las colecciones del mundo juntos

Mapa de puntos

Parquet a objeto espacial

```
library(sf)

eu <- open_dataset("data/gbif_mammals.parquet") |>
  dplyr::select(species, family, decimalLongitude, decimalLatitude) |>
  dplyr::collect() |>
  dplyr::mutate(lon = as.numeric(decimalLongitude),
                lat = as.numeric(decimalLatitude)) |>
  dplyr::filter(dplyr::between(lon, 2, 20),
                dplyr::between(lat, 45, 55))
eu_sf <- st_as_sf(eu, coords = c("lon", "lat"), crs = 4326)
```

1,682,120 puntos, solo Europa Central (2–20°E, 45–55°N)

PMTiles con freestiler

Mosaicos/teselas vectoriales en un solo archivo

```
library(freestiler)

freestile(
  eu_sf, "roedores_europa.pmtiles",
  layer_name = "roedores",
  min_zoom = 3, max_zoom = 12,
  cluster_distance = 50,          # agrupa puntos a zoom bajo
  cluster_maxzoom = 7,
  category = "familia"            # colorea clusters por familia
)
```

Métrica	Valor
Puntos de entrada	1,682,120
Salida	un archivo `.pmtiles`
Tamaño	**79 MB**
Tiempo	**~17 min**, una sola vez

- `category = "familia"` para agrupar por familia a zoom bajo; puntos individuales a zoom alto

Visualizar con mapgl + MapLibre

```r
library(mapgl)

maplibre(style = openfreemap_style("positron"),
         center = c(11, 50), zoom = 4.5) |>
  add_pmtiles_source(id = "roedores",
                     url = "http://localhost:8899/roedores_europa.pmtiles") |>
  add_circle_layer(
    id = "pts", source = "roedores", source_layer = "roedores",
    circle_color = match_expr(
      column = "familia",
      values = c("Cricetidae","Sciuridae","Castoridae","Muridae",
                 "Myocastoridae","Gliridae","Otras"),
      stops = c("#1b9e77","#d95f02","#7570b3","#e7298a",
                "#66a61e","#e6ab02","#999999")),
    circle_radius = 3, circle_opacity = 0.6)
```

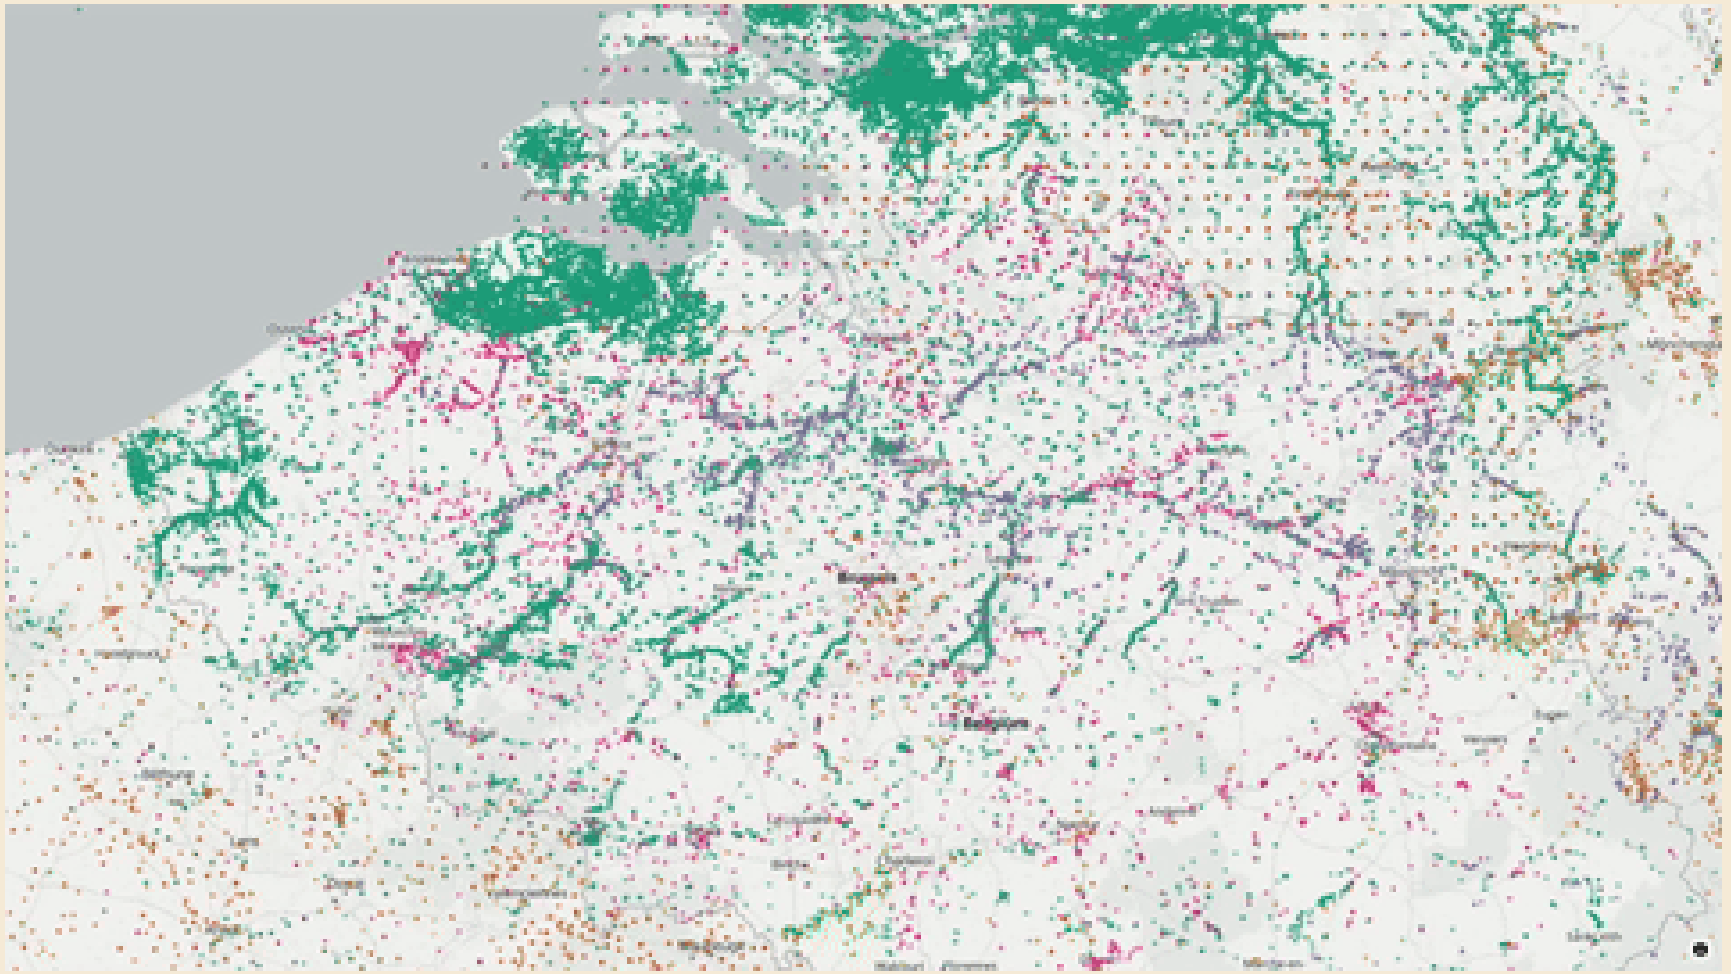

1.68 M de registros de roedores, Europa central

Datos espaciales masivos: BOTW

- **Birds of the World (2025)**: distribuciones geográficas de aves
- GeoPackage de **8.7 GB**, **11,170** especies en 17,377 filas
- Cargar como objeto `sf` en memoria colapsa el IDE

Filtrar sin cargar en memoria con `duckspatial`

¿Qué especies están presentes en México?

```
1 library(duckspatial)
2
3 con <- ddbs_create_conn(dbdir = "memory")
4 botw <- ddbs_open_dataset("BOTW_2025.gpkg", conn = con)
5 ddbs_write_table(con, mexico_sf, "mexico")
6
7 # El filtro ocurre en DuckDB; solo llegan a R los resultados
8 botw_mx <- ddbs_filter(botw, "mexico", predicate = "intersects", conn = cor
9   ddbs_collect(as = "sf")
```

Se procesaron 17,377 geometrías; solo 1,679 llegan al entorno de trabajo de R

Enfoque	Resultado
`sf::st_read()` + filtro (8.7 GB a memoria)	**Colapsa R**
`ddbs_open_dataset()` + `ddbs_filter()`	**1,679 especies en 2.5 m**

Filtro no espacial

Seleccionar 600 especies al azar, sin leer las geometrías

```
# Solo se recolectan los nombres; no las geometrías
species_600 <- botw |>
  distinct(sci_name) |>
  collect() |>
  dplyr::pull(sci_name) |>
  sample(600)

# DuckDB filtra y R recibe solo las cinco columnas solicitadas
botw_600 <- botw |>
  dplyr::filter(sci_name %in% species_600) |>
  dplyr::select(sisid, sci_name, presence, origin, seasonal) |>
  dplyr::collect()
```

Resultado: filtrar 600 especies

Operación	Resultado
Filtrar 600 de 11,170 especies al azar	**1.2 min**
Datos recibidos en R	600 especies; 5 columnas; sin geometrías

Datos estructurados desde PDFs con ellmer

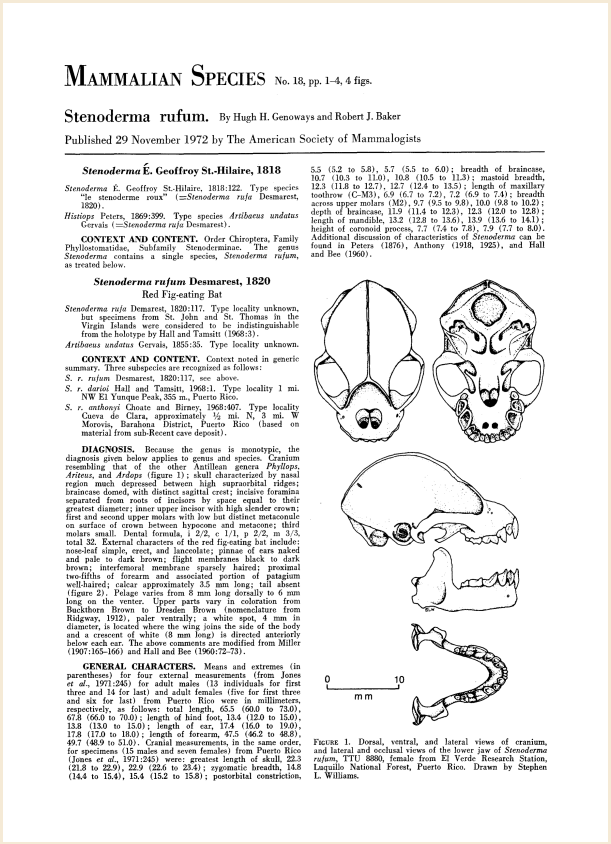

MAMMALIAN SPECIES No. 18, pp. 1–4, 4 figs.

Stenoderma rufum. By Hugh H. Genoways and Robert J. Baker

Published 29 November 1972 by The American Society of Mammalogists

***Stenoderma* É. Geoffroy St.-Hilaire, 1818**

Stenoderma É. Geoffroy St.-Hilaire, 1818:122. Type species "le stenoderme roux" (=*Stenoderma rufa* Desmarest, 1820).

Histiops Peters, 1869:399. Type species *Artibaeus undatus* Gervais (=*Stenoderma rufa* Desmarest).

CONTEXT AND CONTENT. Order Chiroptera, Family Phyllostomatidae, Subfamily Stenoderminae. The genus *Stenoderma* contains a single species, *Stenoderma rufum*, as treated below.

***Stenoderma rufum* Desmarest, 1820**
Red Fig-eating Bat

Stenoderma rufa Desmarest, 1820:117. Type locality unknown, but specimens from St. John and St. Thomas in the Virgin Islands were considered to be indistinguishable from the holotype by Hall and Tamsitt (1968:3).

Artibaeus undatus Gervais, 1855:35. Type locality unknown.

CONTEXT AND CONTENT. Context noted in generic summary. Three subspecies are recognized as follows:

S. r. rufum Desmarest, 1820:117, see above.

S. r. darioi Hall and Tamsitt, 1968:1. Type locality 1 mi. NW El Yunque Peak, 355 m., Puerto Rico.

S. r. anthonyi Choate and Birney, 1968:407. Type locality Cueva de Clara, approximately ½ mi. N, 3 mi. W Morovis, Barahona District, Puerto Rico (based on material from sub-Recent cave deposit).

DIAGNOSIS. Because the genus is monotypic, the diagnosis given below applies to genus and species. Cranium resembling that of the other Antillean genera *Phyllops*, *Ariteus*, and *Ardops* (figure 1); skull characterized by nasal region much depressed between high supraorbital ridges; braincase domed, with distinct sagittal crest; incisive foramina separated from roots of incisors by space equal to their greatest diameter; inner upper incisor with high slender crown; first and second upper molars with low but distinct metaconule on surface of crown between hypocone and metacone; third molars small. Dental formula, i 2/2, c 1/1, p 2/2, m 3/3, total 32. External characters of the red fig-eating bat include: nose-leaf simple, erect, and lanceolate; pinnae of ears naked and pale to dark brown; flight membranes black to dark brown; interfemoral membrane sparsely haired; proximal two-fifths of forearm and associated portion of patagium well-haired; calcar approximately 3.5 mm long; tail absent (figure 2). Pelage varies from 8 mm long dorsally to 6 mm long on the venter. Upper parts vary in coloration from Buckthorn Brown to Dresden Brown (nomenclature from Ridgway, 1912), paler ventrally; a white spot, 4 mm in diameter, is located where the wing joins the side of the body and a crescent of white (8 mm long) is directed anteriorly below each ear. The above comments are modified from Miller (1907:165–166) and Hall and Bee (1960:72–73).

GENERAL CHARACTERS. Means and extremes (in parentheses) for four external measurements (from Jones *et al.*, 1971:245) for adult males (13 individuals for first three and 14 for last) and adult females (five for first three and six for last) from Puerto Rico were in millimeters, respectively, as follows: total length, 65.5 (60.0 to 73.0), 67.8 (66.0 to 70.0); length of hind foot, 13.4 (12.0 to 15.0), 13.8 (13.0 to 15.0); length of ear, 17.4 (16.0 to 19.0), 17.8 (17.0 to 18.0); length of forearm, 47.5 (46.2 to 48.8), 49.7 (48.9 to 51.0). Cranial measurements, in the same order, for specimens (15 males and seven females) from Puerto Rico (Jones *et al.*, 1971:245) were: greatest length of skull, 22.3 (21.8 to 22.9), 22.9 (22.6 to 23.4); zygomatic breadth, 14.8 (14.4 to 15.4), 15.4 (15.2 to 15.8); postorbital constriction, 5.5 (5.2 to 5.8), 5.7 (5.5 to 6.0); breadth of braincase, 10.7 (10.3 to 11.0), 10.8 (10.5 to 11.3); mastoid breadth, 12.3 (11.8 to 12.7), 12.7 (12.4 to 13.5); length of maxillary toothrow (C–M3), 6.9 (6.7 to 7.2), 7.2 (6.9 to 7.4); breadth across upper molars (M2), 9.7 (9.5 to 9.8), 10.0 (9.8 to 10.2); depth of braincase, 11.9 (11.4 to 12.3), 12.3 (12.0 to 12.8); length of mandible, 13.2 (12.8 to 13.6), 13.9 (13.6 to 14.1); height of coronoid process, 7.7 (7.4 to 7.8), 7.9 (7.7 to 8.0). Additional discussion of characteristics of *Stenoderma* can be found in Peters (1876), Anthony (1918, 1925), and Hall and Bee (1960).

FIGURE 1. Dorsal, ventral, and lateral views of cranium, and lateral and occlusal views of the lower jaw of *Stenoderma rufum*, TTU 8880, female from El Verde Research Station, Luquillo National Forest, Puerto Rico. Drawn by Stephen L. Williams.

Ficha de *Stenoderma rufum* en PDF escaneado (sin OCR)

Objetivo: extraer valores de rasgos como datos estructurados, sin transcripción manual

Extracción estructurada con ellmer

```r
library(ellmer)
chatpdfs <- chat_openai(
  model = "gpt-6-luna",
  system_prompt = "extract data from scientific papers"
)
mybatfile <- content_pdf_file("data/PDF/stenoderma.pdf")
of_interest <- type_object(
  scientific_name = type_string("focal species of the document"),
  forearm_length_M = type_number("forearm length (mm), males"),
  forearm_length_F = type_number("forearm length (mm), females"),
  ear_length = type_number("ear length (mm)"))
)
bat_info <- chatpdfs$chat_structured(
  "extract the trait values", mybatfile, type = of_interest
)
```

Resultado

Campo	Valor
scientific_name	Stenoderma rufum
forearm_length_M	47.5
forearm_length_F	49.7
forearm_length_min	46.2
forearm_length_max	51.0
ear_length	17.6

El esquema (`type_object`) garantiza salida JSON válida y sin valores inventados. ~0.002 USD por PDF

Ventajas

- **Bajo costo**: software libre, hardware existente
- **Escalable**: millones de registros en laptop de gama baja/media
- **Reproducible**: código versionado, formatos abiertos
- **Interoperable**: formatos multiplaforma y multisistema

Desafíos

- ~~Brecha técnica en programación~~
- Difusión de nuevas herramientas
- Falta de incentivos para liberar y estandarizar datos
- Uso ético y responsable de IA

Conclusiones

- Nuevas herramientas (DuckDB, Arrow, Parquet, etc) democratizan el trabajo con “Big Data”
- Podemos modernizar los flujos de trabajo sin inversión en infraestructura costosa

Gracias

Luis D. Verde Arregoitia
Instituto de Ecología A. C. (INECOL)

liomys.mx maevolab.mx